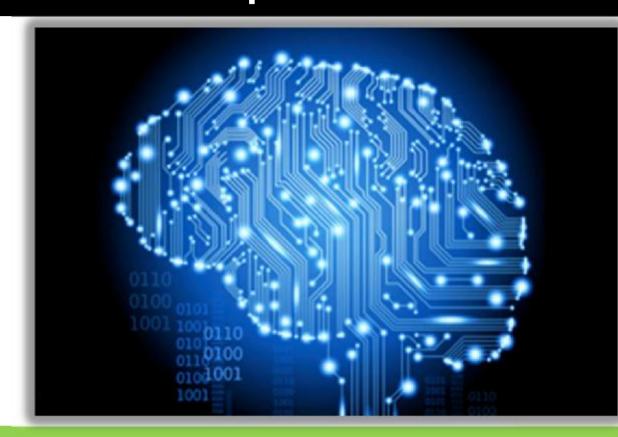
PISL 03

Кодирование Хаффмана + heap





Кафедра экономической информатики Бгуир, 201

PISL Lesson03. Код Хаффмана + heap

Советы по решению задач на программирование

- Тестируйте решение перед отправкой на git.
- ПРИ КОПИРОВАНИИ ПАПОК КОПИРУЙТЕ ВСЕ и тесты и за-
- Если вы скопировали тест, а задачу нет то у других людей проект не будет собираться. По этой же причине не держите ваши решения вне git. Даже недоделанные – отправляйте.
- Если проект все-таки не собирается из-за чужих ошибок, не исправляйте их, а просто отключите чужие папки (ПКМ -> Mark Directory -> Excluded).
- Проверяйте ваше решение при граничных значениях параметра: если в задаче на вход даётся, скажем, массив размера 1\leq n\leq 10000, проверяйте, как ваша программа ведёт себя при n=1,2,10000.
- Следите за переполнением типов. Например, если в вашем коде на перемножаются две переменные типа int высокого порядка, то результат перемножения может не поместиться в тип int.
- Получить представление об асимптотике ожидаемого решения можно по заданным ограничениям на размер входа. Как правило чтобы уложиться во временные рамки (несколько секунд), программа должна совершать до миллиарда операций. Соответственно, при ограничениях 1≤п≤10000, скорее всего,
- \circ ожидается решение с асимптотикой $O(n^2)$ или O(n log n), о а при 1≤n≤10⁶ – с асимптотикой O(n) или O(n log n).
- Для удобства при прохождении тестов работает main и наоборот.

Литература

Разобраться по сути:

- С. Дасгупта, Х. Пападимитриу, У. Вазирани. Алгоритмы. МЦНМО. 2014.
- Т. Кормен, Ч. Лейзерсон, Р. Ривест, К. Штайн. Алгоритмы: построение и анализ. Вильямс. 2013.

Минимум для собеседований

• Лафоре Р. Структуры данных и алгоритмы в Java. Классика Computers Science. 2-е изд. — СПб.: Питер, 2013. — 704 с.: ил. - (Серия «Классика computer science»)

По желанию

• А. Шень. Программирование: теоремы и задачи. МЦНМО. 2014.

В качестве математической подготовки к курсу можно прочесть брошюры Александра Шеня «Логарифм и экспонента» и «Математическая индукция».

PISL Lesson03. Код Хаффмана + heap

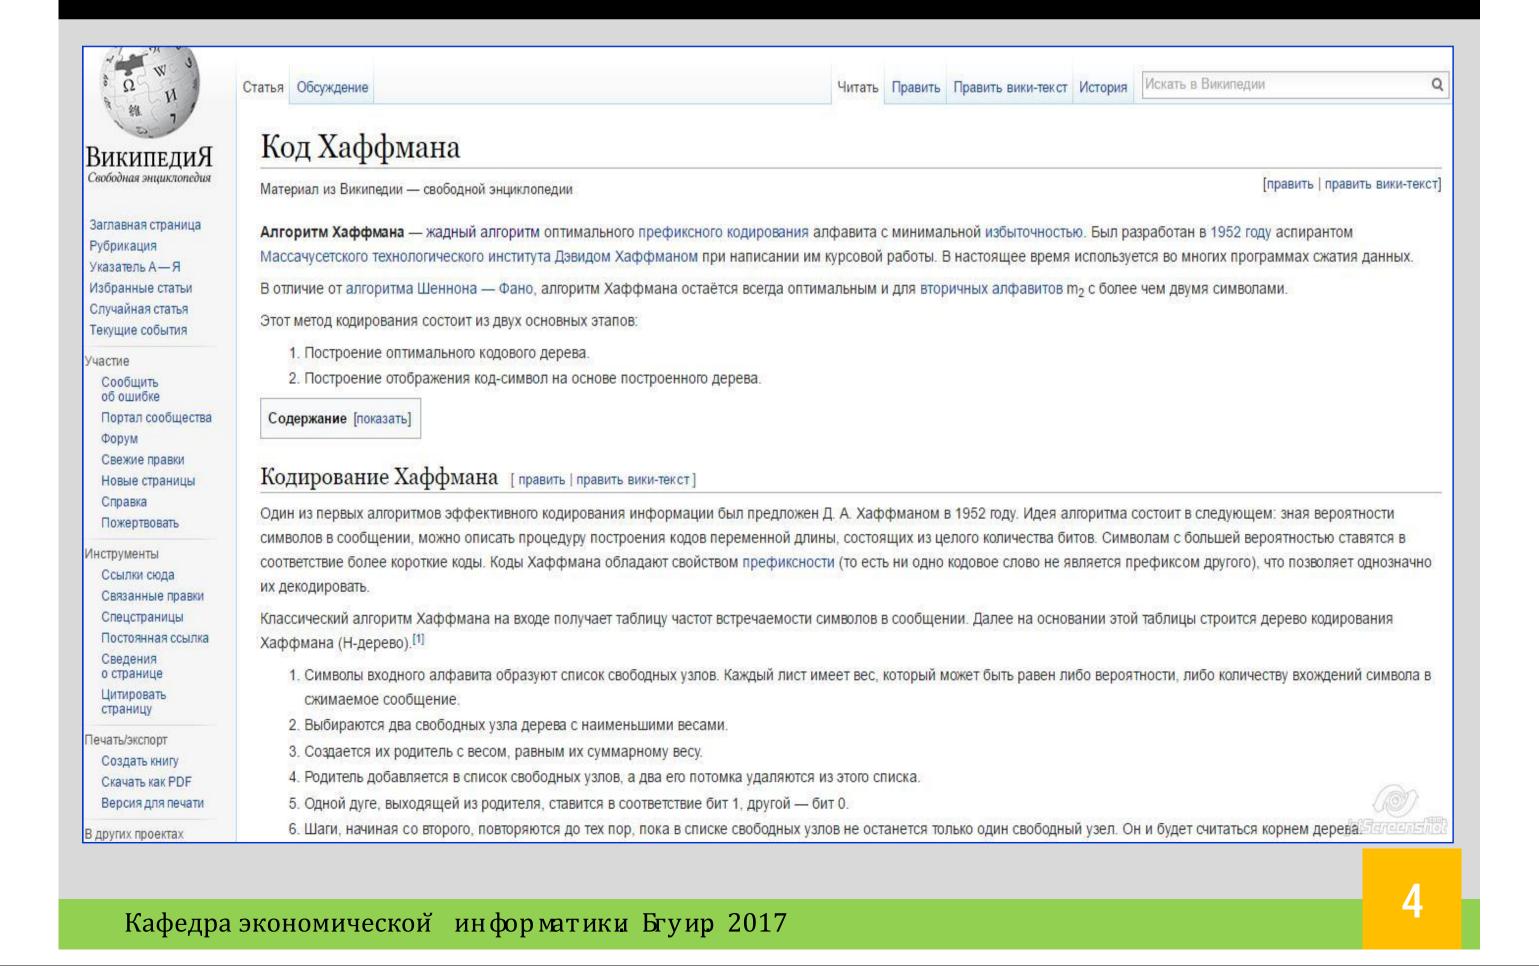
- Определение.
- Жадный алгоритм кодирование Хаффмана.
- Идея алгоритма
 - наивный алгорит
 - оптимальный алгорит
- Дерево, как удобная структура для кодирования
 - принцип работы. Код Хаффмана.
 - Формальное описание алгоритма построения дерева
- Куча структура данных для приоритетных очередей, сортировок и т.д.
- Задачи кодирование (А) декодирование (В) своя реализация кучи (С)

Материалы: http://tinyurl.com/ei-pisl

https://github.com/Khmelov/PISL2017-01-26 Github:

Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap



Допустим, у нас есть следующая таблица частот:

 Символ
 A
 Б
 B
 Г
 Д

 Частота
 15
 7
 6
 6
 5

Этот процесс можно представить как построение дерева, корень которого — символ с суммой вероятностей объединенных символов, получившийся при объединении символов из последнего шага, его n₀ потомков — символы из предыдущего шага и т. д.

Чтобы определить код для каждого из символов, входящих в сообщение, мы должны пройти путь от листа дерева, соответствующего текущему символу, до его корня, накапливая биты при перемещении по ветвям дерева (первая ветвь в пути соответствует младшему биту). Полученная таким образом последовательность битов является кодом данного символа, записанным в обратном порядке.

Для данной таблицы символов коды Хаффмана будут выглядеть следующим образом.

 Символ
 A
 Б
 B
 Г
 Д

 Код
 0
 100
 101
 110
 111

Поскольку ни один из полученных кодов не является префиксом другого, они могут быть однозначно декодированы при чтении их из потока. Кроме того, наиболее частый символ сообщения А закодирован наименьшим количеством бит, а наиболее редкий символ Д — наибольшим.

При этом общая длина сообщения, состоящего из приведённых в таблице символов, составит 87 бит (в среднем 2,2308 бита на символ). При использовании равномерного кодирования общая длина сообщения составила бы 117 бит (ровно 3 бита на символ). Заметим, что энтропия источника, независимым образом порождающего символы с указанными частотами, составляет ~2,1858 бита на символ, то есть избыточность построенного для такого источника кода Хаффмана, понимаемая как отличие среднего числа бит на символ от энтропии, составляет менее 0,05 бит на символ.

Классический алгоритм Хаффмана имеет ряд существенных недостатков. Во-первых, для восстановления содержимого сжатого сообщения декодер должен знать таблицу частот, которой пользовался кодер. Следовательно, длина сжатого сообщения увеличивается на длину таблицы частот, которая должна посылаться впереди данных, что может свести на нет все усилия по сжатию сообщения. Кроме того, необходимость наличия полной частотной статистики перед началом собственно кодирования

требует двух проходов по сообщению: одного для построения модели сообщения (таблицы частот и H-дерева), другого для собственно кодирования. Во-вторых, избыточность кодирования обращается в ноль лишь в тех случаях, когда вероятности кодируемых символов являются обратными степенями числа 2. В-третьих, для источника с энтропией, не превышающей 1 (например, для двоичного источника), непосредственное применение кода Хаффмана бессмысленно.

Кафедра экономической информатики Бгуир 2017

Į

Построение дерева для данного примера

PISL Lesson03. Код Хаффмана + heap

Коды переменной длины

■ Естественная идея: присвоить более короткие коды более частым символам.

PISL Lesson03. Код Хаффмана + heap

Сжатие данных

Вход: строка s.

Выход: бинарный код символов строки s,

обеспечивающий кратчайшее представление s.

Пример

s = abacabad

коды символов: a: 00, b: 01, c: 10, d: 11

закодированная строка: 0001001000010011 (16 битов)

Кафедра экономической информатики Бгуир 2017

6

PISL Lesson03. Код Хаффмана + heap

Коды переменной длины

- Естественная идея: присвоить более короткие коды более частым символам.
- s = abacabad коды символов: a: 0, b: 10, c: 110, d: 111 закодированная строка: 01001100100111 (14 битов)

Коды переменной длины

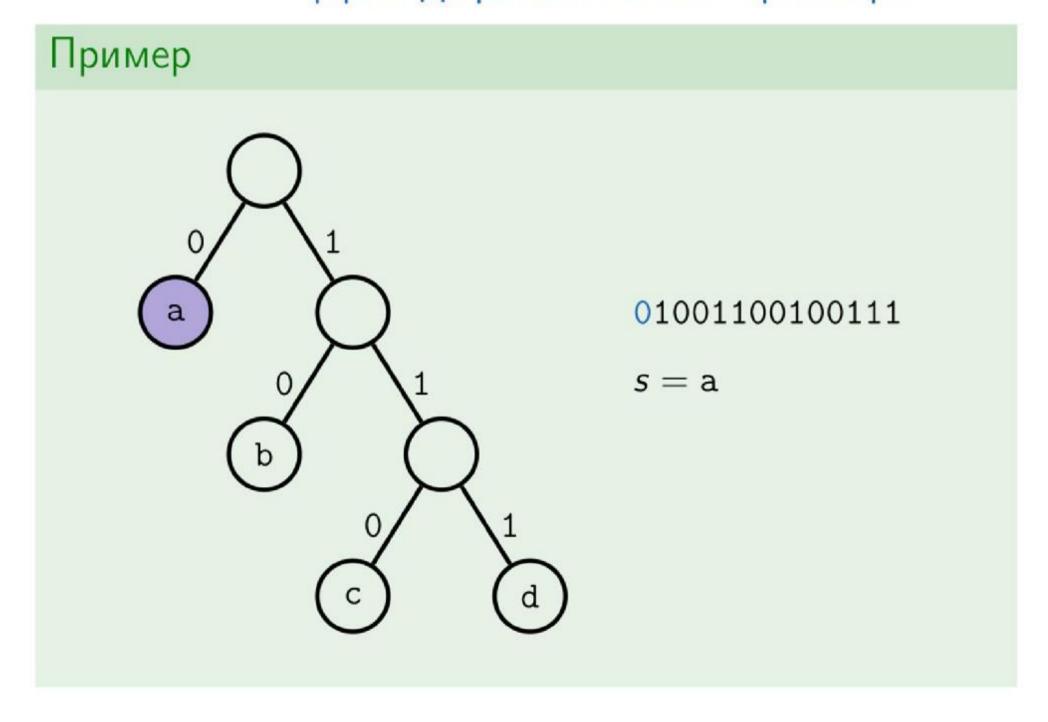
- Естественная идея: присвоить более короткие коды более частым символам.
- s = abacabad коды символов: a: 0, b: 10, c: 110, d: 111 закодированная строка: 01001100100111 (14 битов)
- Код называется беспрефиксным, если никакой код символа не является префиксом другого кода символа.

Кафедра экономической информатики Бгуир 2017

9

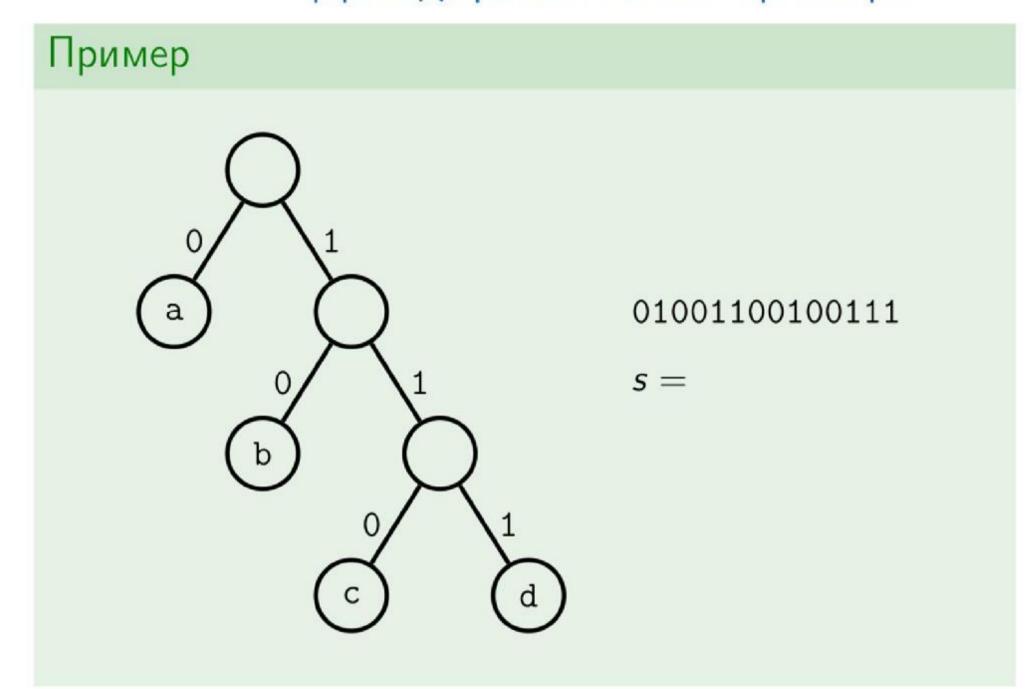
PISL Lesson03. Код Хаффмана + heap

Декодирование на примере



PISL Lesson03. Код Хаффмана + heap

Декодирование на примере

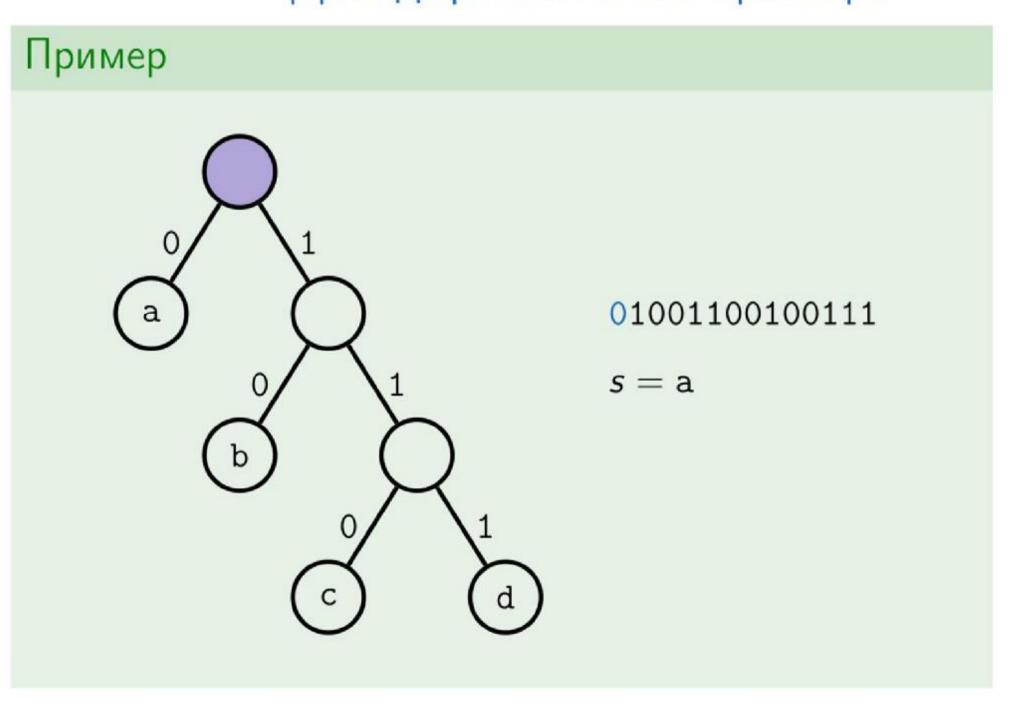


Кафедра экономической информатики Бгуир 2017

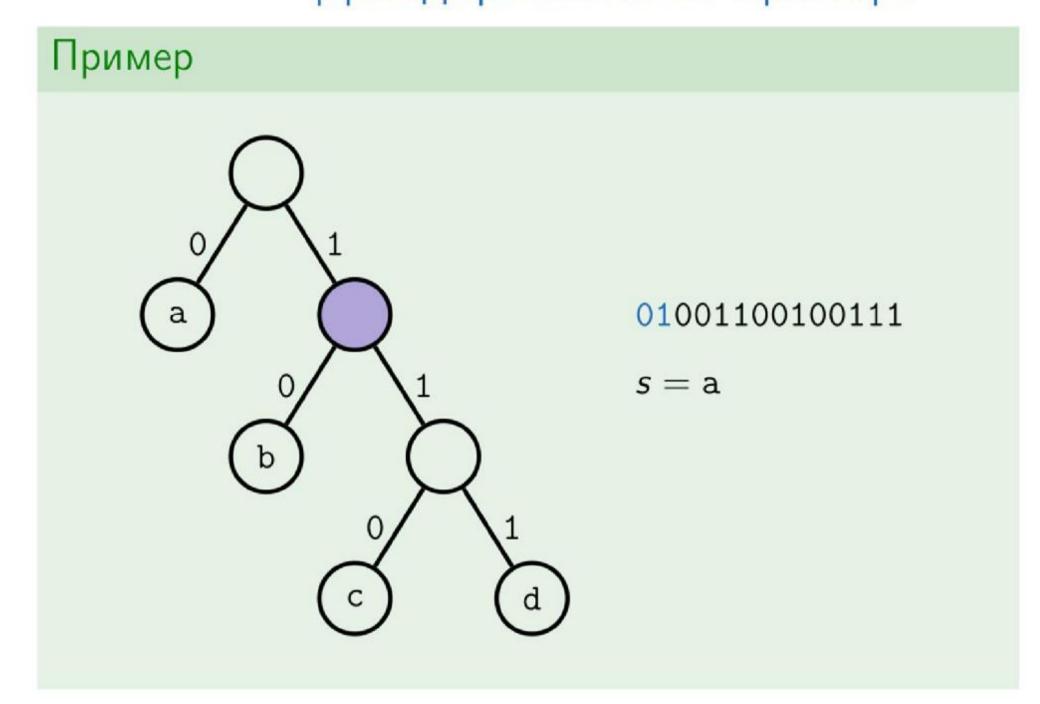
10

PISL Lesson03. Код Хаффмана + heap

Декодирование на примере



Декодирование на примере

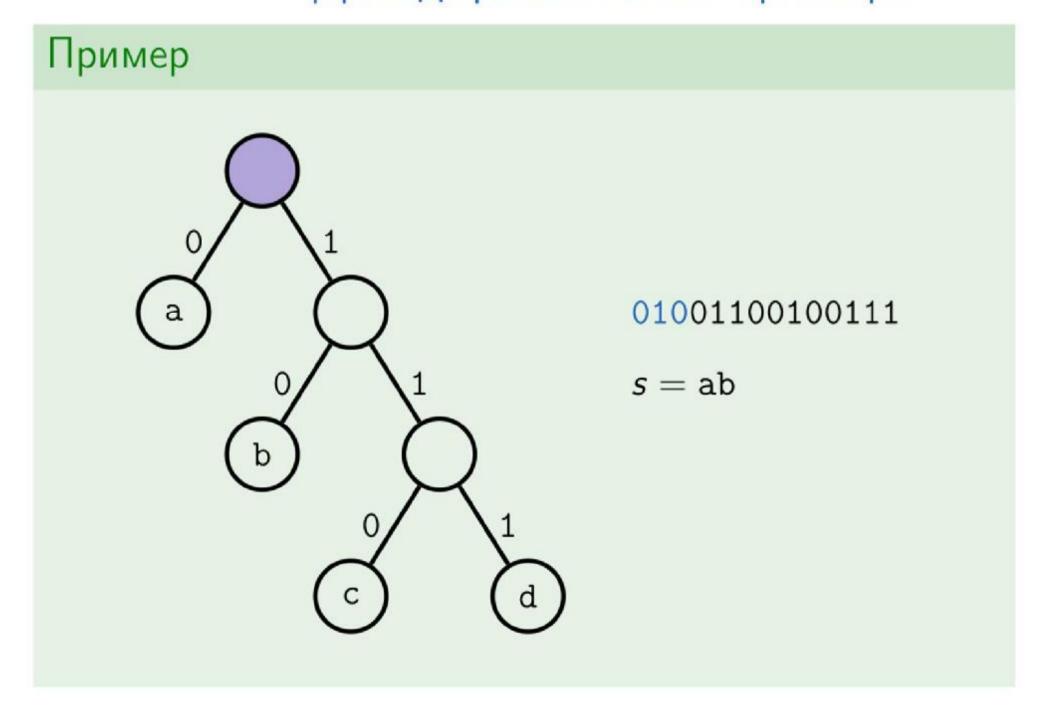


Кафедра экономической информатики Бгуир 2017

13

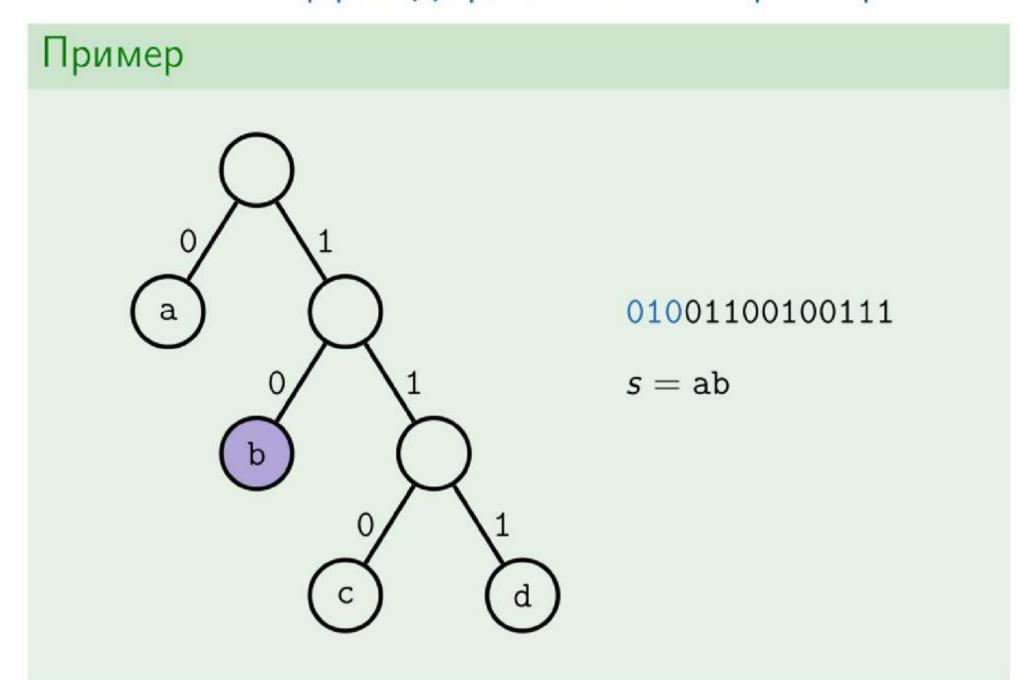
PISL Lesson03. Код Хаффмана + heap

Декодирование на примере



PISL Lesson03. Код Хаффмана + heap

Декодирование на примере



Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap

Код Хаффмана

Код Хаффмана

Вход: частоты символов $f_1, \ldots, f_n \in \mathbb{N}$.

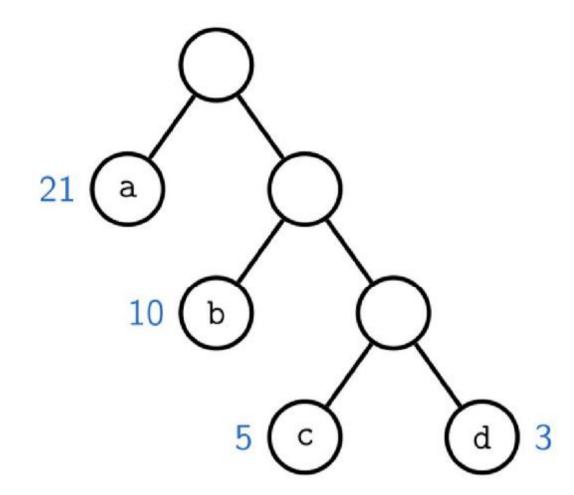
Выход: строго двоичное дерево (у каждой вершины

либо ноль, либо два сына), листья которого

помечены частотами f_1, \ldots, f_n , минимизирующее

 $\sum_{i=1}^{n} f_i \cdot ($ глубина листа f_i).

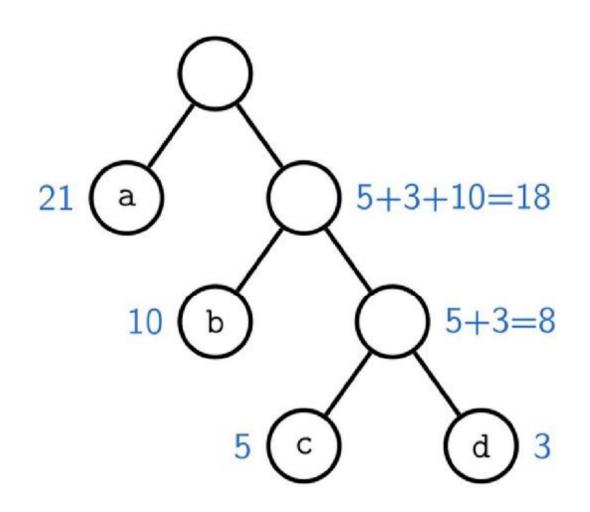
Частоты для внутренних вершин



Кафедра экономической информатики Бгуир 2017

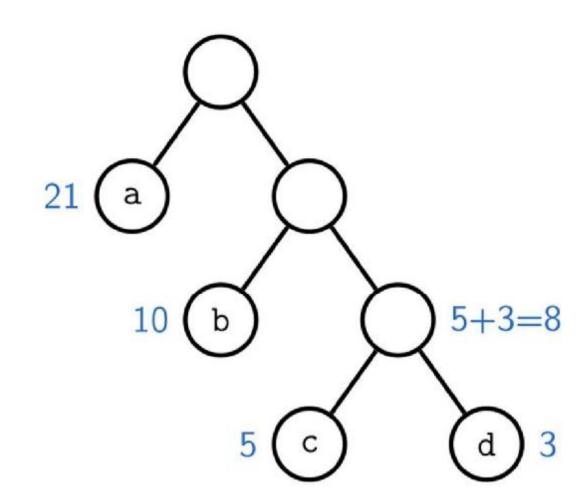
PISL Lesson03. Код Хаффмана + heap

Частоты для внутренних вершин



PISL Lesson03. Код Хаффмана + heap

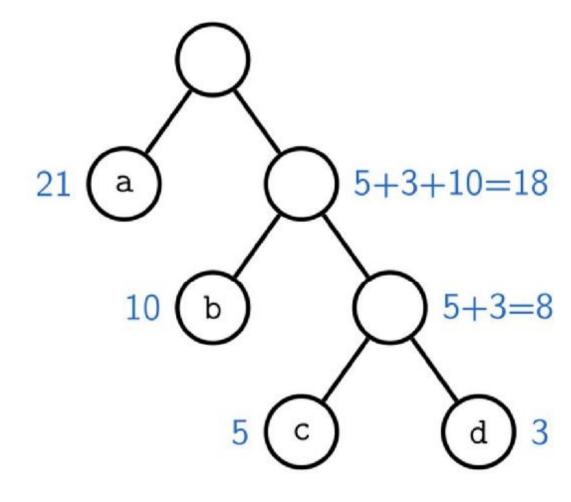
Частоты для внутренних вершин



Кафедра экономической информатики Бгуир 2017

PISL Lesson03. **Код Хаффмана** + heap

Частоты для внутренних вершин



Частотой (некорневой) вершины назовём количество раз, которое вершина будет посещена в процессе кодировки/декодировки.

18

Надёжный шаг

■ Таким образом, мы ищем строго двоичное дерево с минимальной суммой пометок в вершинах, в котором листья помечены входными частотами, а внутренние вершины — суммами пометок их детей.

Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap

Надёжный шаг

- Таким образом, мы ищем строго двоичное дерево с минимальной суммой пометок в вершинах, в котором листья помечены входными частотами, а внутренние вершины — суммами пометок их детей.
- Двумя наименьшими частотами помечены листья на нижнем уровне.
- Надёжный жадный шаг: выбрать две минимальные частоты f_i и f_j , сделать их детьми новой вершины с пометкой $f_i + f_j$; выкинуть частоты f_i и f_j , добавить $f_i + f_j$.

PISL Lesson03. Код Хаффмана + heap

Надёжный шаг

- Таким образом, мы ищем строго двоичное дерево с минимальной суммой пометок в вершинах, в котором листья помечены входными частотами, а внутренние вершины — суммами пометок их детей.
- Двумя наименьшими частотами помечены листья на нижнем уровне.

Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap

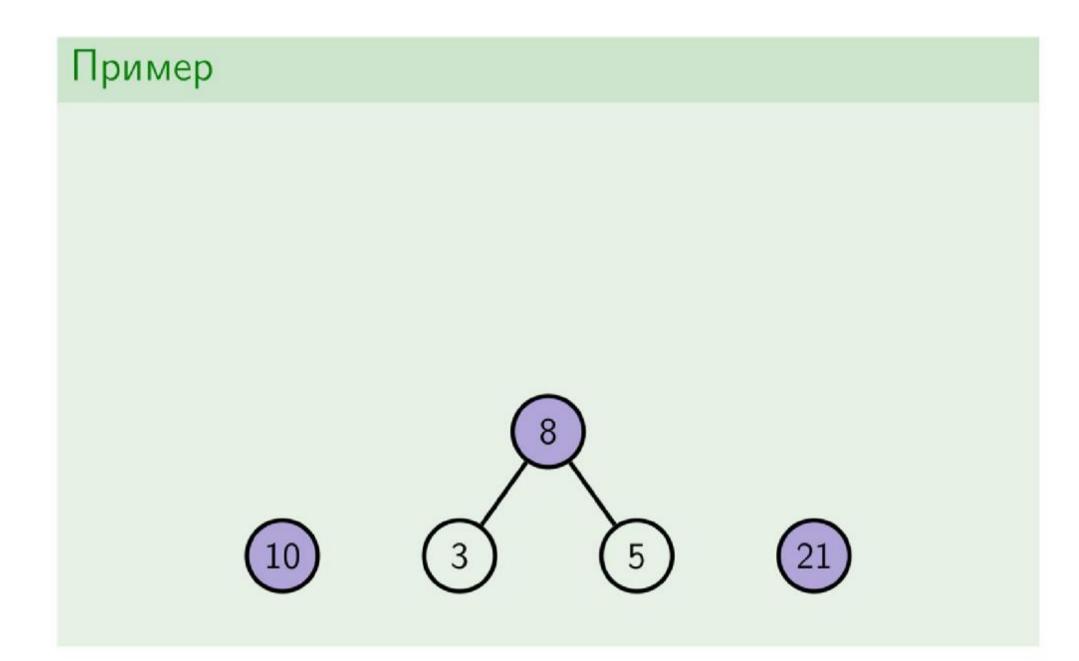
Пример





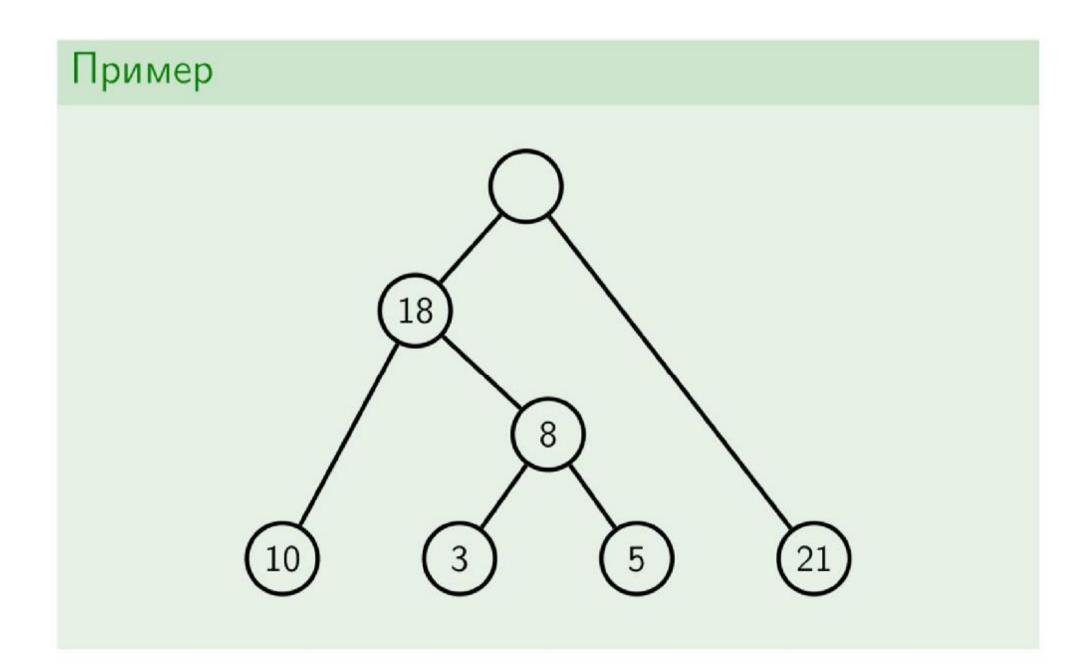




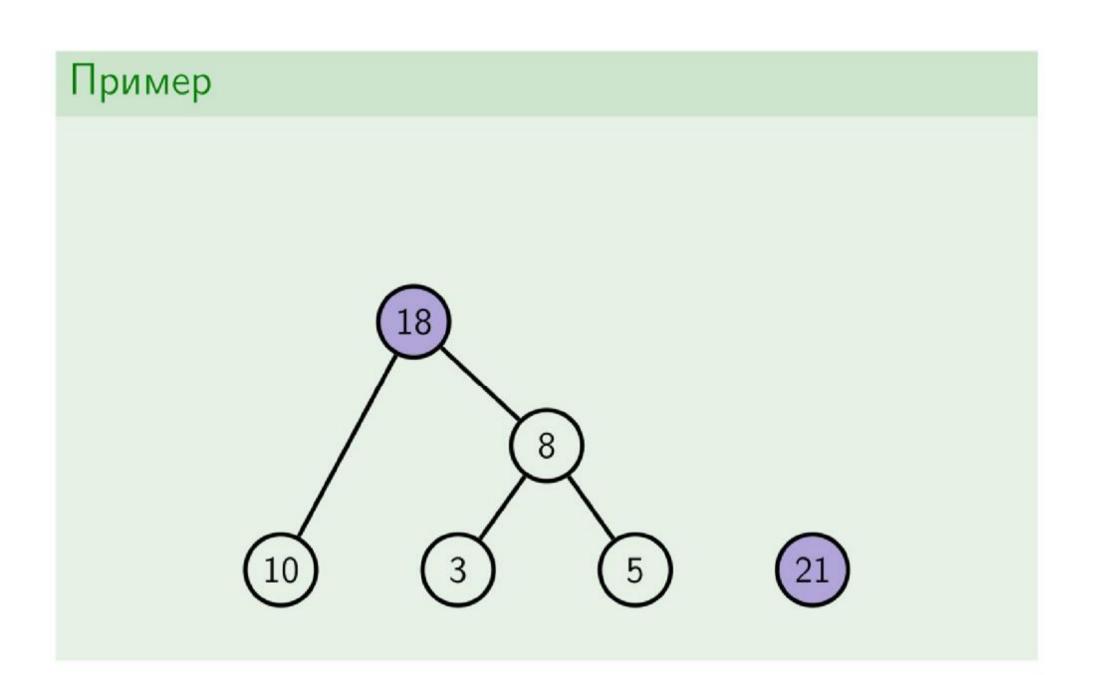


Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap



PISL Lesson03. Код Хаффмана + heap



Кафедра экономической информатики Бгуир 2017

PISL Lesson03. **Код Хаффмана** + heap

Очередь с приоритетами

Insert(p) добавляет новый элемент с приоритетом p ExtractMin() извлекает из очереди элемент с минимальным приоритетом

26

Алгоритм

```
процедура HUFFMAN(F[1...n])

H \leftarrow \text{очередь c приоритетами}
для i от 1 до n:

INSERT(H, (i, F[i]))

для k от n+1 до 2n-1:

(i, F[i]) \leftarrow \text{EXTRACTMIN}(H)

(j, F[j]) \leftarrow \text{EXTRACTMIN}(H)

создать вершину k с детьми i, j

F[k] = F[i] + F[j]

INSERT(H, (k, F[k]))
```

Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap

Алгоритм

```
процедура НОГГМАN (F[1...n])

H \leftarrow очередь с приоритетами
для i от 1 до n:
   INSERT(H, (i, F[i]))
для k от n+1 до 2n-1:
   (i, F[i]) \leftarrow EXTRACTMIN(H)
   (j, F[j]) \leftarrow EXTRACTMIN(H)
   создать вершину k с детьми i, j
F[k] = F[i] + F[j]
   INSERT(H, (k, F[k]))
```

Время работы: $O(n^2)$, если очередь с приоритетами реализована на базе массива, $O(n \log n)$ — если на базе кучи (разберём в следующей лекции).

PISL Lesson03. Код Хаффмана + heap

Алгоритм

```
процедура НИFFMAN(F[1...n])

H \leftarrow очередь с приоритетами
для i от 1 до n:
   INSERT(H, (i, F[i]))
для k от n+1 до 2n-1:
   (i, F[i]) \leftarrow EXTRACTMIN(H)
   (j, F[j]) \leftarrow EXTRACTMIN(H)
   создать вершину k с детьми i, j
F[k] = F[i] + F[j]
   INSERT(H, (k, F[k]))
```

Кафедра экономической информатики Бгуир 2017

30

PISL Lesson03. Код Хаффмана + heap

Очередь с приоритетами

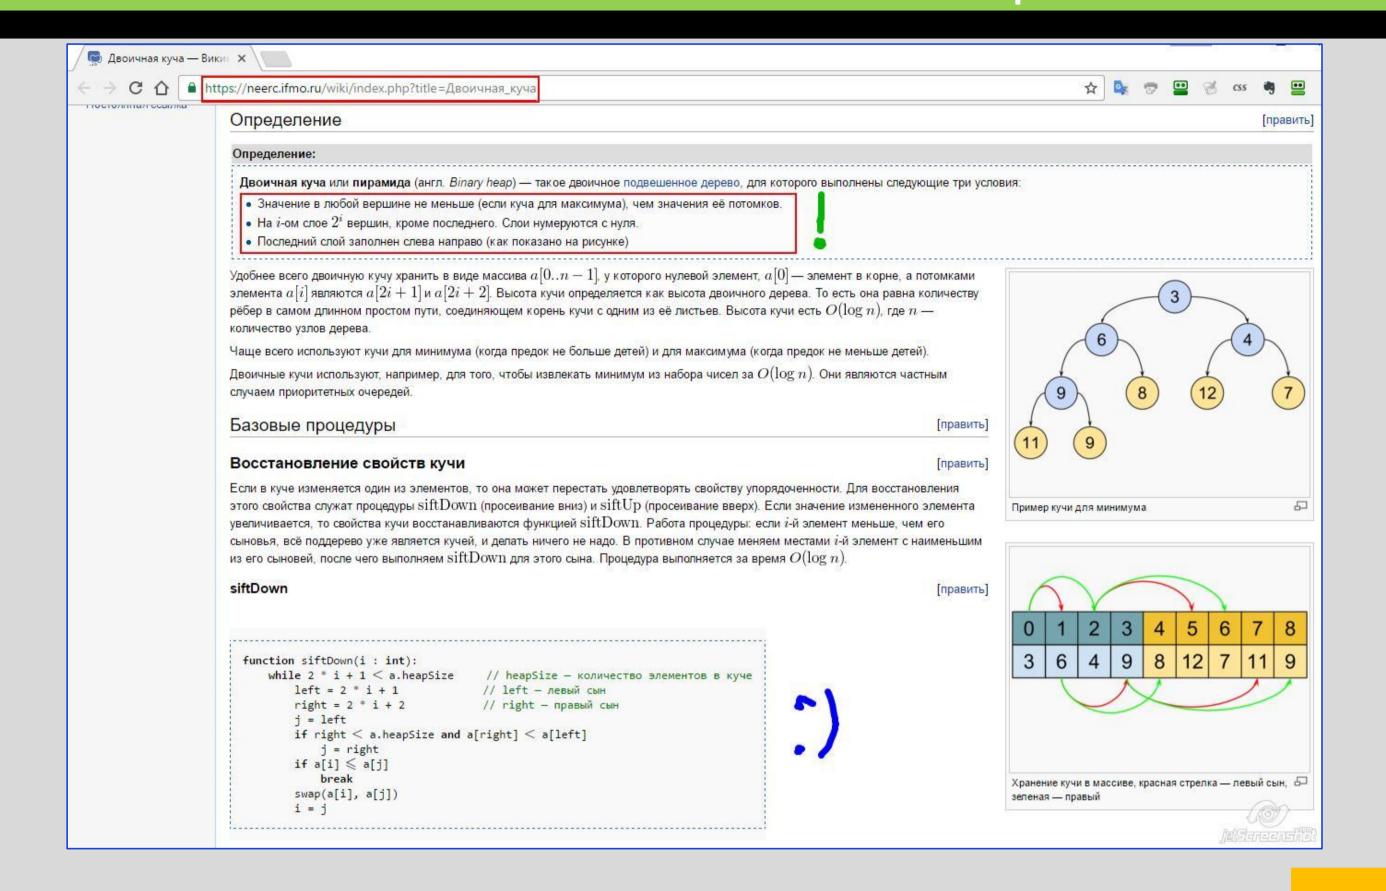
```
Insert(p) добавляет новый элемент с приоритетом p

Remove(it) удаляет элемент, на который указывает итератор it

GetMin() возвращает элемент сіминимальным приоритетом

ExtractMin() извлекает из очереди элемент с минимальным приоритетом

ChangePriority(it, p) изменяет приоритет элемента, на который указывает итератор it, на p
```



Кафедра экономической информатики Бгуир 2017

33

PISL Lesson03. Код Хаффмана + heap

Простейшие реализации

 \blacksquare массив: GETMIN имеет время работы O(n)

3 1 5 4 2

 \blacksquare упорядоченный массив: GetMIN — O(1), Remove — O(n)

PISL Lesson03. Код Хаффмана + heap

Простейшие реализации

 \blacksquare массив: GETMIN имеет время работы O(n)

3 1 5 4 2

13

Кафедра экономической информатики Бгуир 2017

34

PISL Lesson03. Код Хаффмана + heap

Простейшие реализации

 \blacksquare массив: GETMIN имеет время работы O(n)

3 1 5 4 2

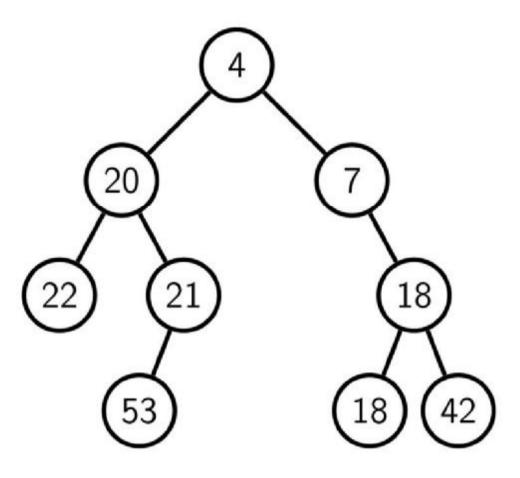
 \blacksquare упорядоченный массив: GetMI \cap O(1), Remove -O(n)

1 2 3 4 5

■ упорядоченный список: GETMIN and REMOVE — O(1), INSERT — O(n)

 $1 \downarrow 2 \downarrow 3 \downarrow 4 \downarrow 5$

Двоичная (мин-)куча



- основное свойство (мин-)кучи: значение вершины ≤ значений её детей
- минимальное значение хранится в корне, поэтому GETMIN работает за время O(1)

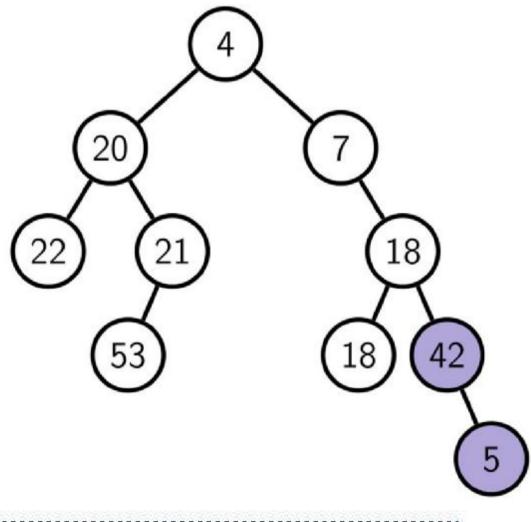
Кафедра экономической информатики Бгуир 2017

37

39

PISL Lesson03. Код Хаффмана + heap

Вставка и просеивание вверх

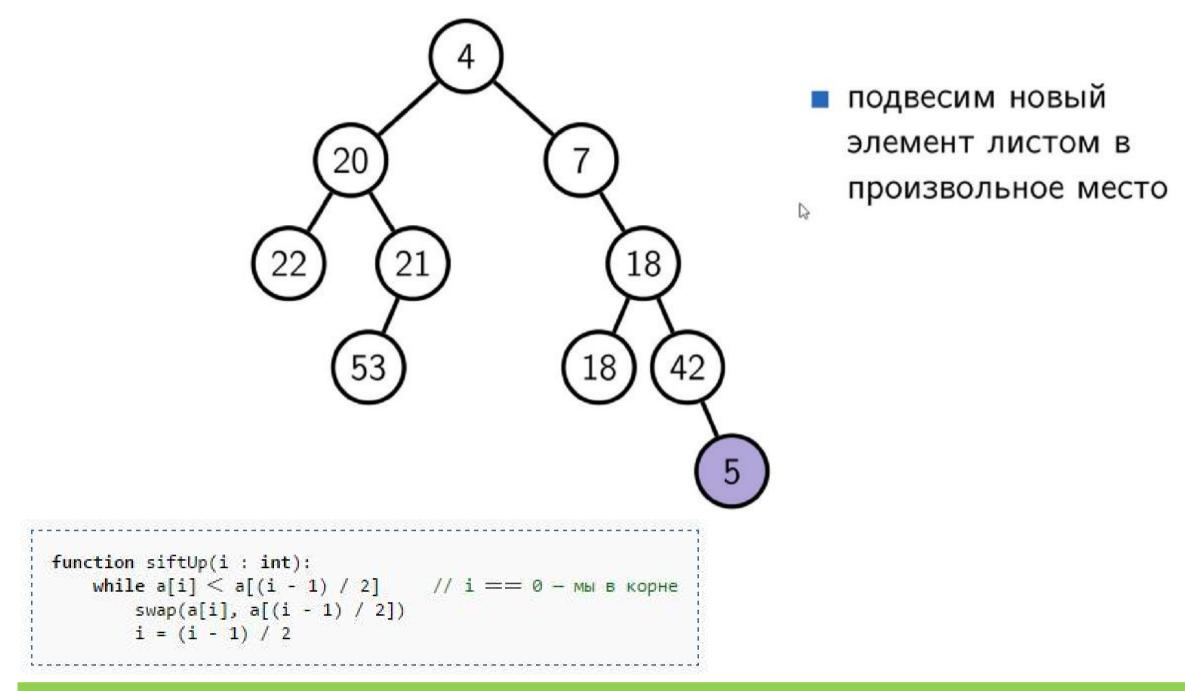


- подвесим новый элемент листом в произвольное место
- начнём чинить свойство кучи, просеивая проблемную вершину вверх

function siftUp(i : int): while a[i] < a[(i-1)/2] // i == 0 — мы в корне swap(a[i], a[(i - 1) / 2])

PISL Lesson03. Код Хаффмана + heap

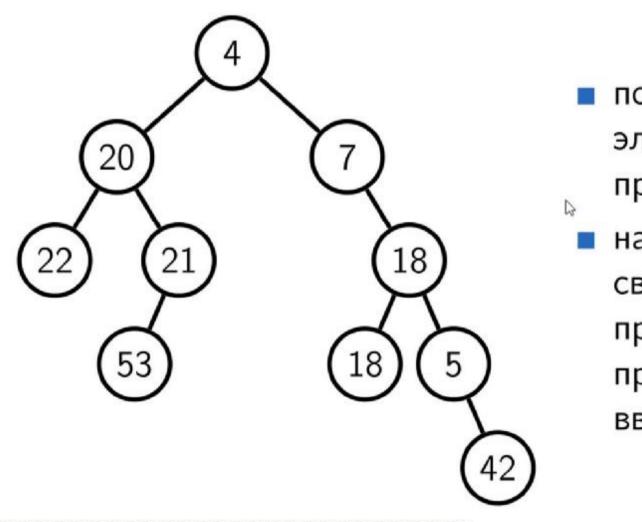
Вставка и просеивание вверх



Кафедра экономической информатики Бгуир 2017

PISL Lesson03. Код Хаффмана + heap

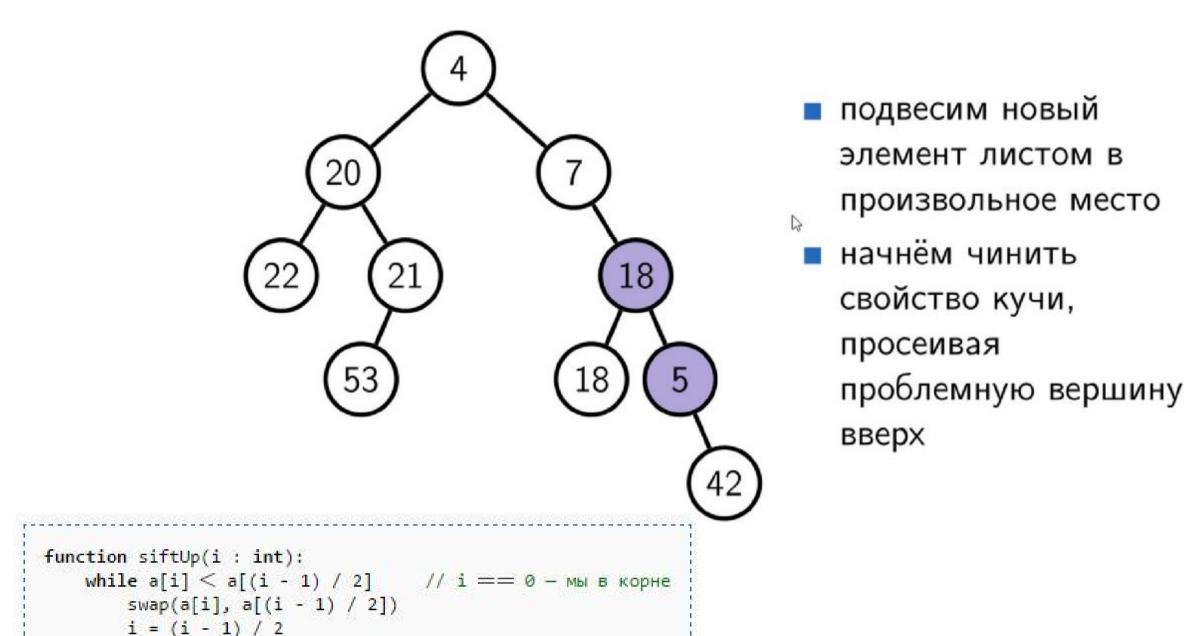
Вставка и просеивание вверх



- подвесим новый элемент листом в произвольное место
- начнём чинить свойство кучи, просеивая проблемную вершину вверх

function siftUp(i : int): while a[i] < a[(i-1)/2] // i == 0 — мы в корне swap(a[i], a[(i-1) / 2])

Вставка и просеивание вверх

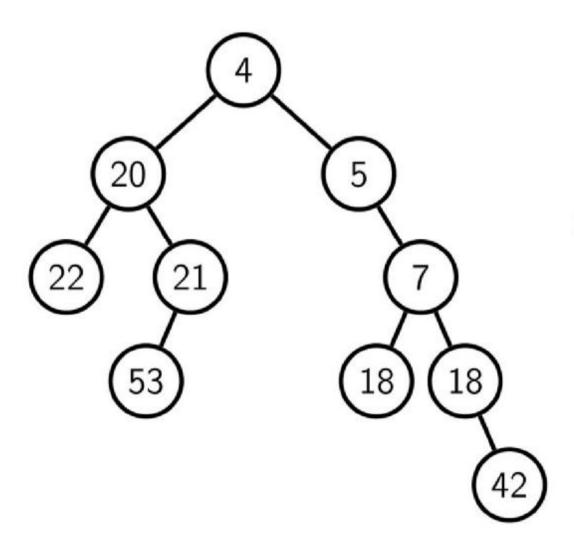


Кафедра экономической информатики Бгуир 2017

4

PISL Lesson03. Код Хаффмана + heap

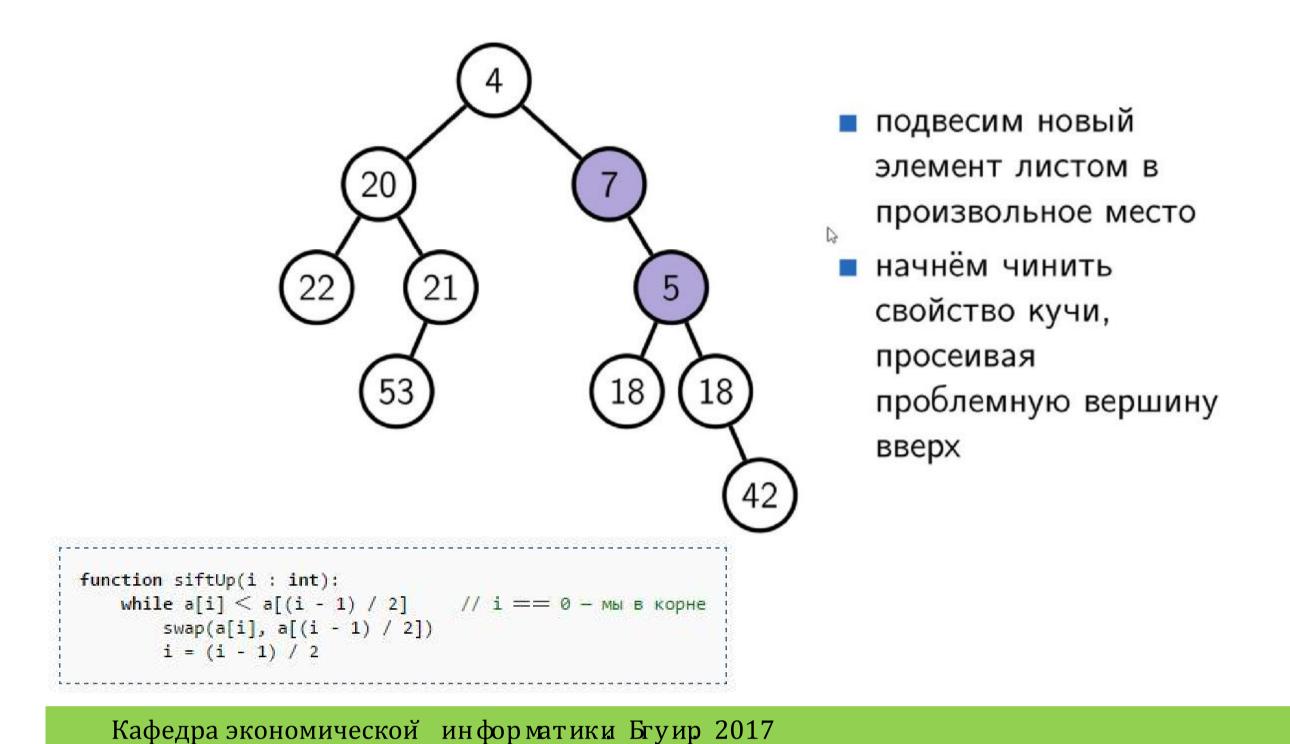
Вставка и просеивание вверх



- подвесим новый элемент листом в произвольное место
- начнём чинить свойство кучи, просеивая проблемную вершину вверх

PISL Lesson03. Код Хаффмана + heap

Вставка и просеивание вверх



PISL Lesson03. Код Хаффмана + heap

Время работы операции вставки

■ важный инвариант: в каждый момент времени свойство кучи нарушено не более чем в одной вершине

Время работы операции вставки

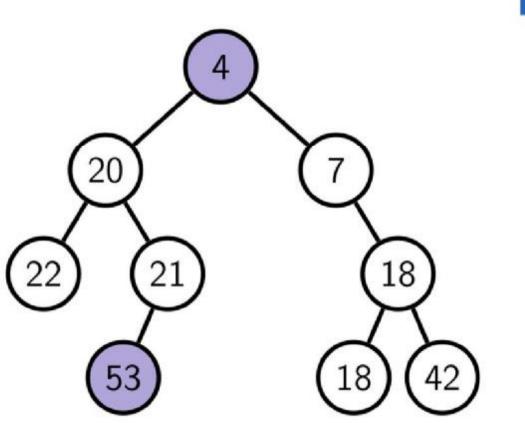
- важный инвариант: в каждый момент времени свойство кучи нарушено не более чем в одной вершине
- при просеивании вверх эта вершина становится ближе к корню

Кафедра экономической информатики Бгуир 2017

45

PISL Lesson03. Код Хаффмана + heap

Извлечение минимума и просеивание вниз



заменим корень на любой лист

B

PISL Lesson03. Код Хаффмана + heap

Время работы операции вставки

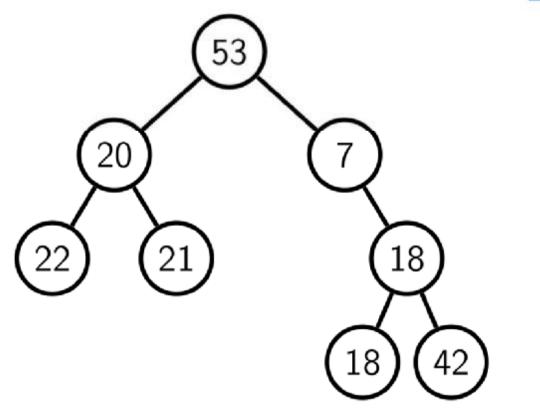
- важный инвариант: в каждый момент времени свойство кучи нарушено не более чем в одной вершине
- при просеивании вверх эта вершина становится ближе к корню
- \blacksquare время работы есть O(h), где h высота кучи

Кафедра экономической информатики Бгуир 2017

46

PISL Lesson03. Код Хаффмана + heap

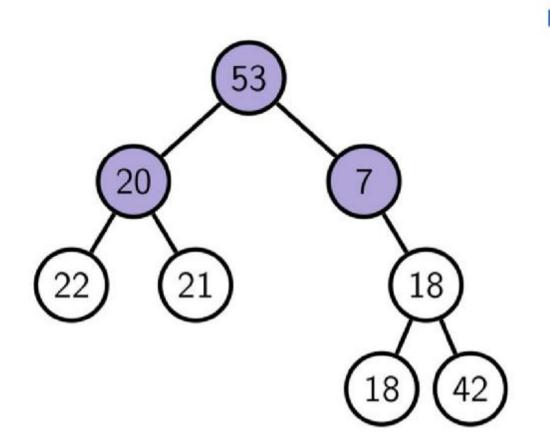
Извлечение минимума и просеивание вниз



заменим корень на любой лист

B

Извлечение минимума и просеивание вниз



заменим корень на любой лист

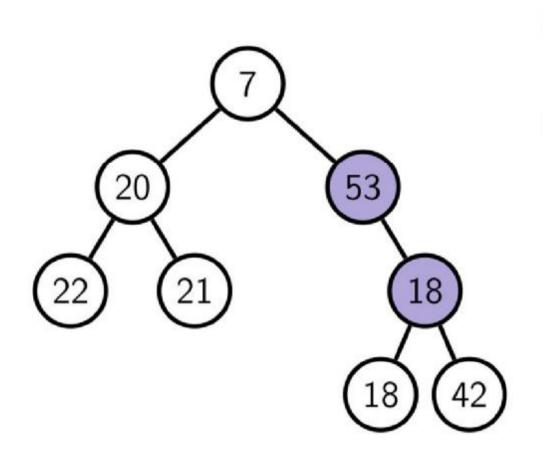
Δ

Кафедра экономической информатики Бгуир 2017

49

PISL Lesson03. Код Хаффмана + heap

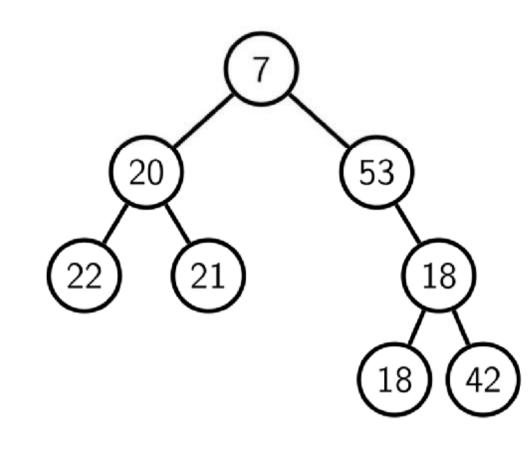
Извлечение минимума и просеивание вниз



- заменим корень на любой лист
- обменяем проблемную вершину с меньшим из её детей, чтобы быть уверенными, что продолжать чинить кучу нужно только в одном из поддеревьев

PISL Lesson03. Код Хаффмана + heap

Извлечение минимума и просеивание вниз

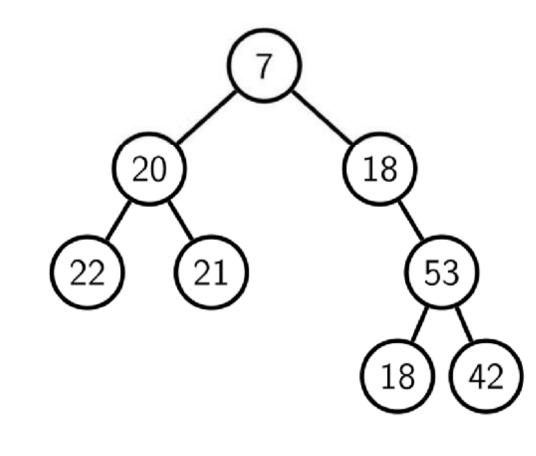


- заменим корень на любой лист
- обменяем проблемную вершину с меньшим из её детей, чтобы быть уверенными, что продолжать чинить кучу нужно только в одном из поддеревьев

Кафедра экономической информатики Бгуир 2017

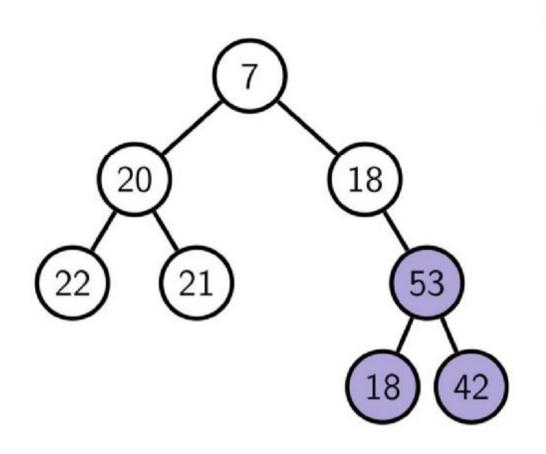
PISL Lesson03. Код Хаффмана + heap

Извлечение минимума и просеивание вниз



- заменим корень на любой лист
- обменяем проблемную вершину с меньшим из её детей, чтобы быть уверенными, что продолжать чинить кучу нужно только в одном из поддеревьев

Извлечение минимума и просеивание вниз



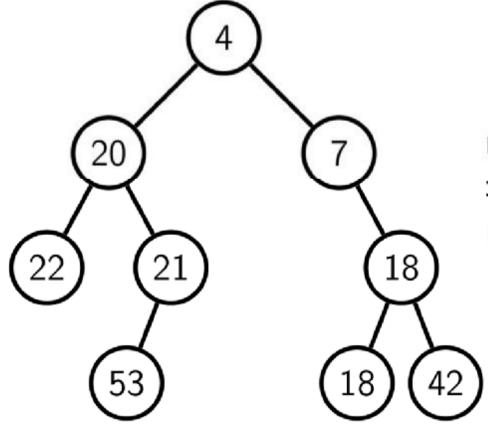
- заменим корень на любой лист
- обменяем проблемную вершину с меньшим из её детей, чтобы быть уверенными, что продолжать чинить кучу нужно только в одном из поддеревьев

Кафедра экономической информатики Бгуир 2017

53

PISL Lesson03. Код Хаффмана + heap

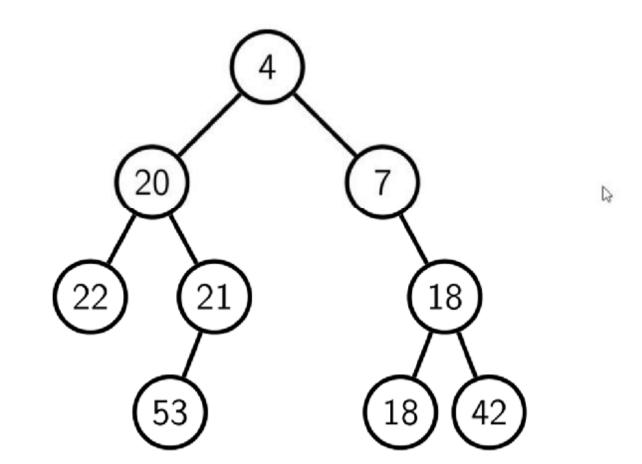
Изменение приоритета



изменим приоритет и дадим элементу просеиться вниз или вверх

PISL Lesson03. Код Хаффмана + heap

Изменение приоритета

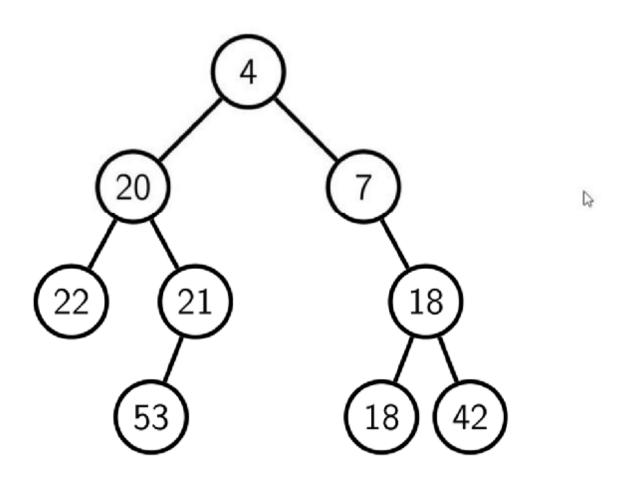


Кафедра экономической информатики Бгуир 2017

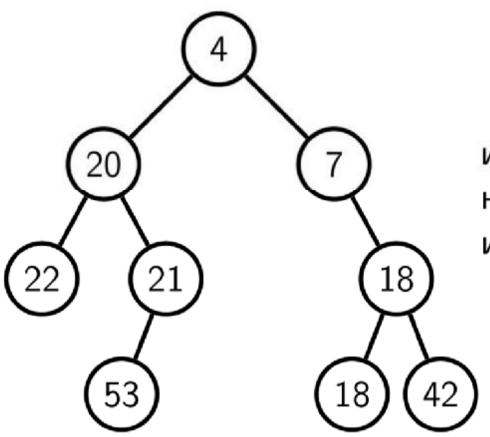
54

PISL Lesson03. Код Хаффмана + heap

Удаление



Удаление



изменим приоритет элемента на $-\infty$, просеим его вверх и извлечём минимум

Кафедра экономической информатики Бгуир 2017

57

PISL Lesson03. Код Хаффмана + heap

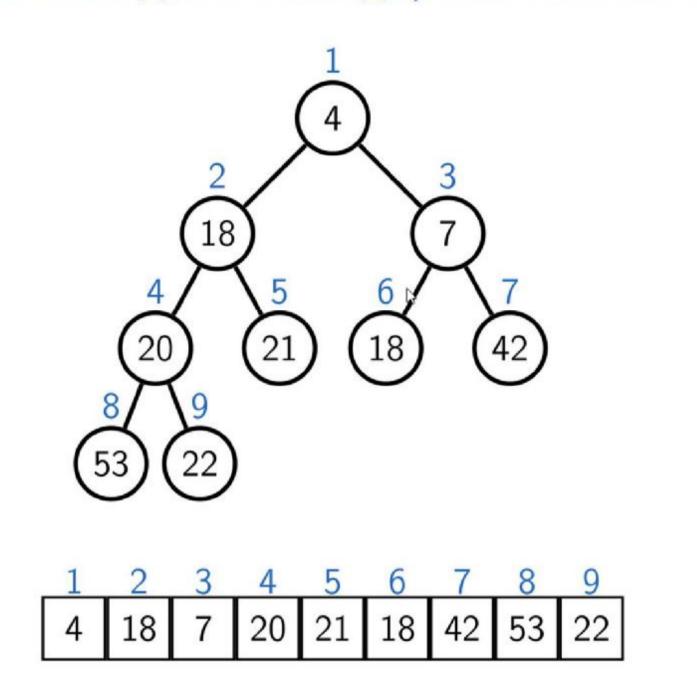
Куча на массиве

 полное двоичное дерево: уровни заполняются слева направо; все уровни заполнены полностью, кроме, возможно, последнего

B

PISL Lesson03. Код Хаффмана + heap

Полное двоичное дерево и массив



Кафедра экономической информатики Бгуир 2017

58

PISL Lesson03. Код Хаффмана + heap

Куча на массиве

- полное двоичное дерево: уровни заполняются слева направо; все уровни заполнены полностью, кроме, возможно, последнего
- естественная нумерация вершин: сверху вниз, слева направо

B

Куча на массиве

- полное двоичное дерево: уровни заполняются слева направо; все уровни заполнены полностью, кроме, возможно, последнего
- естественная нумерация вершин: сверху вниз, слева направо
- при добавлении элемента подвешиваем лист на последний уровень; при удалении отрезаем самый последний лист

Кафедра экономической информатики Бгуир 2017

61

Задание А. Кодирование Хаффмана

```
//Lesson 3. A Huffman.
                                  //Разработайте метод encode (File file) для кодирования строки (код Хаффмана)
by
                                  // По данным файла (непустой строке ss длины не более 104104),
  lesson01
                                  // состоящей из строчных букв латинского алфавита,
    ▼ lesson02
                                  // постройте оптимальный по суммарной длине беспрефиксный код.
        B_Sheduler
                                  // Используйте Алгоритм Хаффмана — жадный алгоритм оптимального
        © ™ C_GreedyKnapsack
        greedyKnapsack.txt
                                  // безпрефиксного кодирования алфавита с минимальной избыточностью.
        C & Lesson2Test
    ▼ lesson03
                                  // В первой строке выведите количество различных букв kk,
        C a A Huffman
                                  // встречающихся в строке, и размер получившейся закодированной строки.
        C & B_Huffman
        C_HeapMax
                                  // В следующих kk строках запишите коды букв в формате "letter: code".
        dataHuffman.txt
                                   // В последней строке выведите закодированную строку. Примеры ниже
        encodeHuffman.txt
        testHeap.txt
                                             Sample Input 1:
  alesnax
  apilipenka
  astro_emelya
  belash ea
                                             Sample Output 1:
  chatovich
                                             1 1
  grishkevich
                                             a: 0
  hustlestar
  jahstreet
  khadasevich
                                             Sample Input 2:
  makstra
  ▶ ■ mrlokans
                                                                     "H:\Program Files\Java\jdk1.8.0_101\bin\java" ...
                                              abacabad
  rudkouski
                                                                     a: 0
  sardika
                                                                     b: 10
                                             Sample Output 2:
                                                                     c: 110
  sergey_dubatovka
                                                                     d: 111
                                             4 14
  sergeybelush
                                                                     0100110010011:
                                             a: 0
  stereoby
                                                                     Process finished with exit code 0
  v_zhukovski
                                             b: 10
  vadimsquorpikkor
```

PISL Lesson03. Код Хаффмана + heap

Куча на массиве

- полное двоичное дерево: уровни заполняются слева направо; все уровни заполнены полностью, кроме, возможно, последнего
- естественная нумерация вершин: сверху вниз, слева направо
- при добавлении элемента подвешиваем лист на последний уровень; при удалении отрезаем самый последний лист
- вершина i имеет родителя $\lfloor i/2 \rfloor$ и детей 2i и 2i+1 (при вычислении данных индексов нужно проверять, что они попадают в отрезок [1, n])

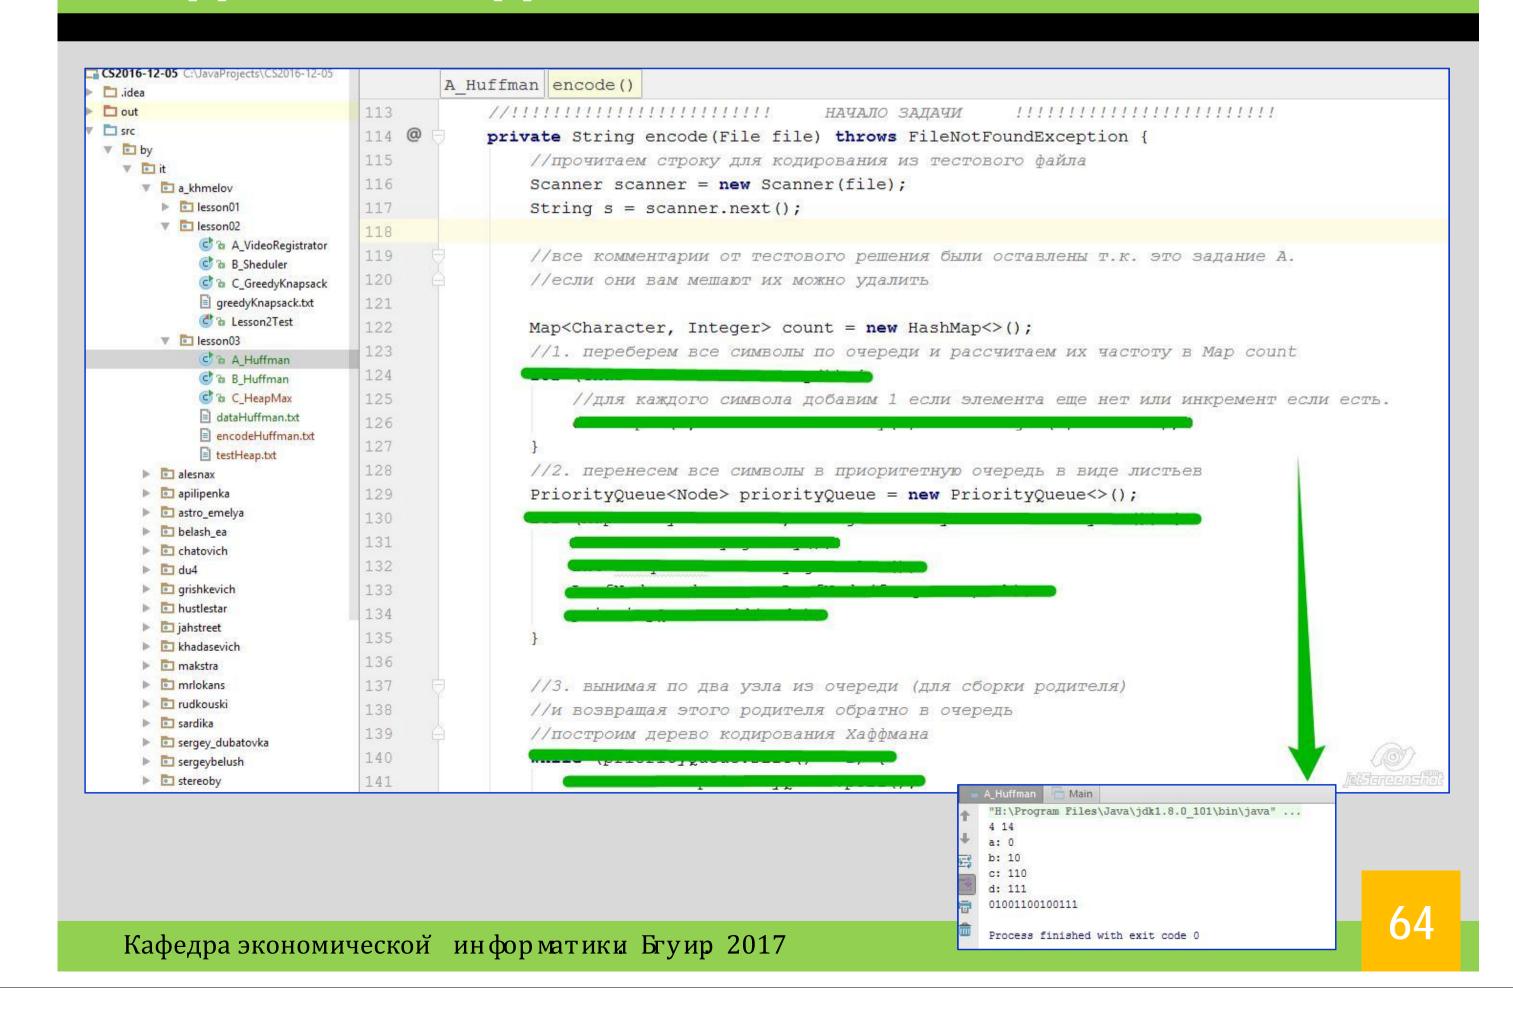
Построение кучи из «хаоса»

function heapify():
 for i = a.heapSize / 2 downto 0
 siftDown(i)

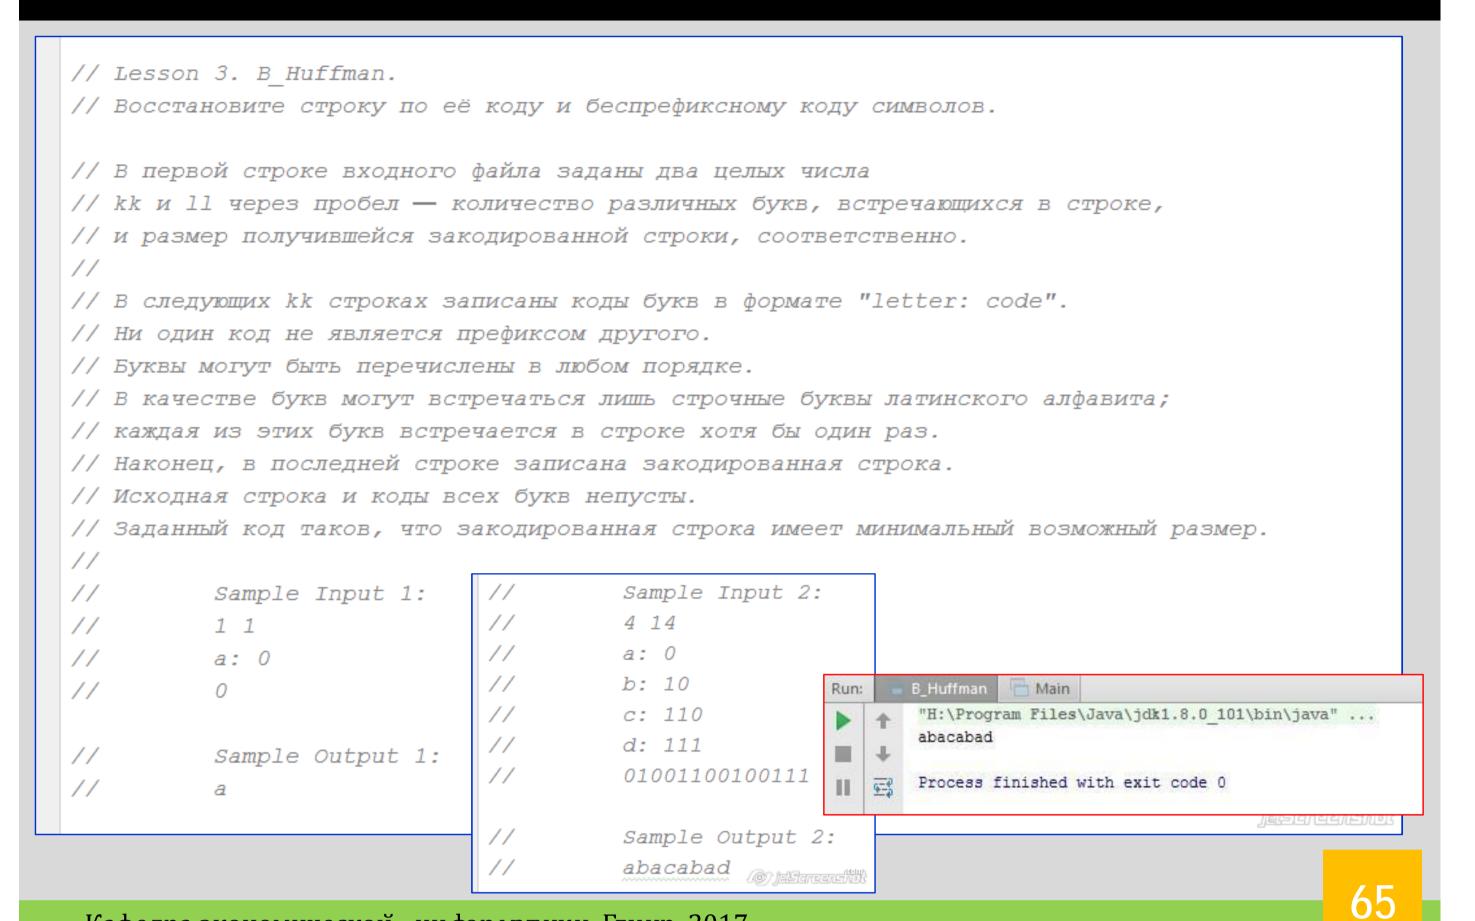
Кафедра экономической информатики Бгуир 2017

62

Задание А. Кодирование Хаффмана

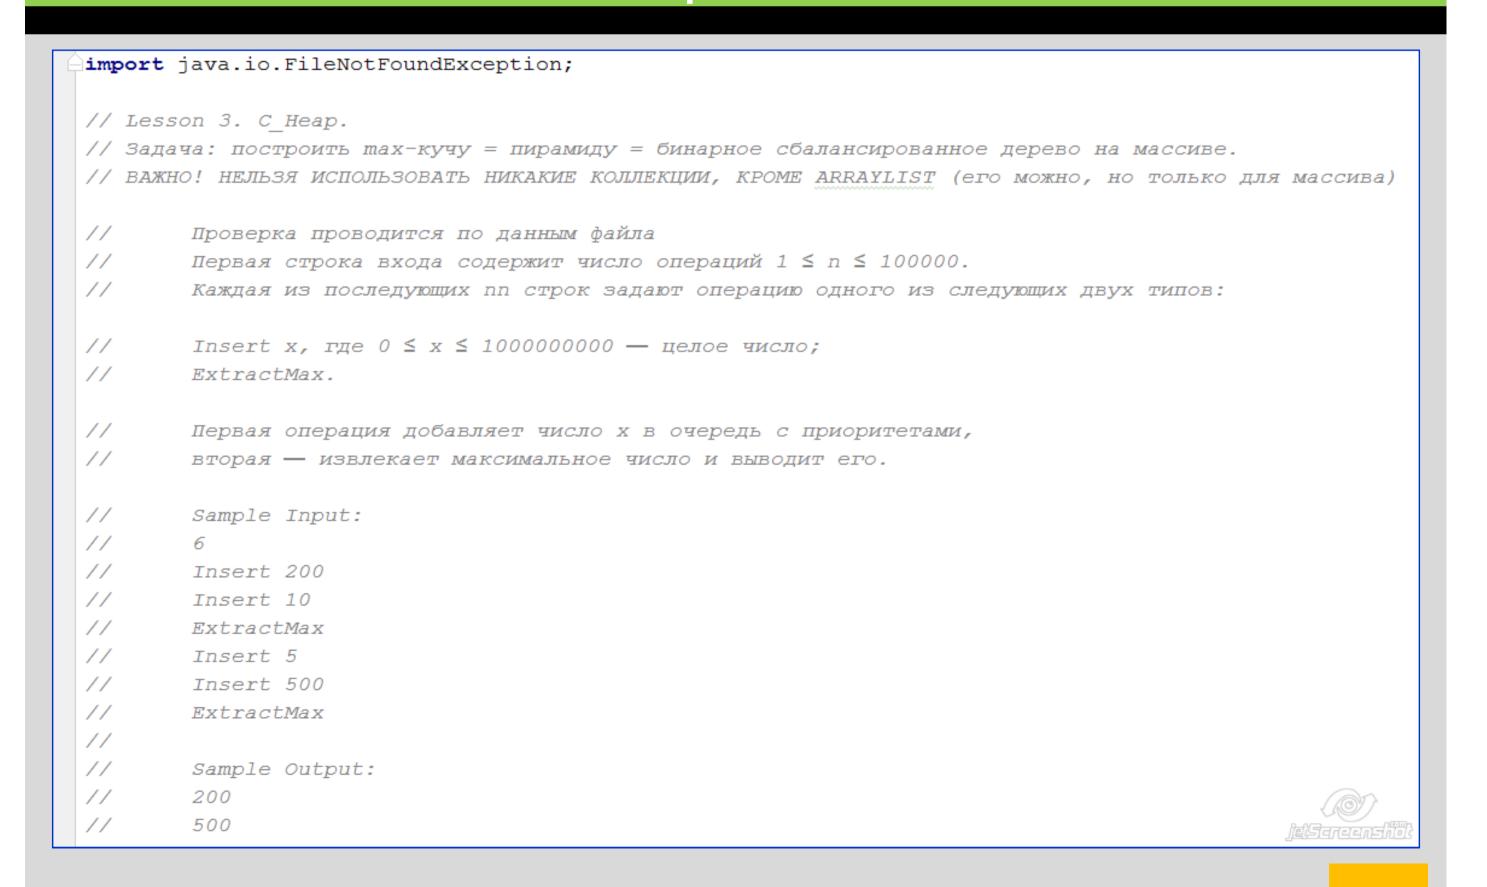


Задание Б. Декодирование Хаффмана

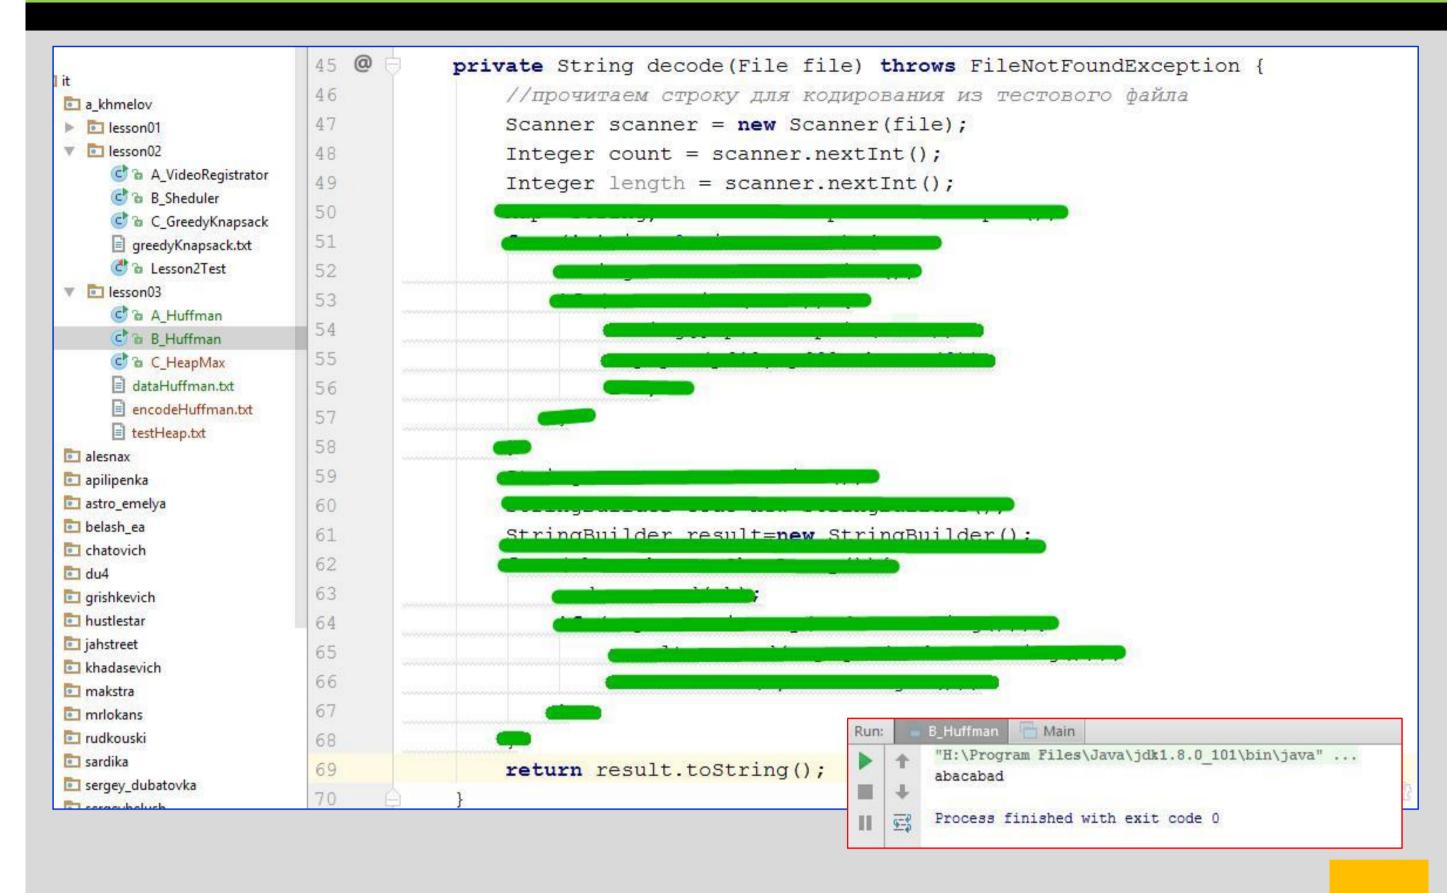


Кафедра экономической информатики Бгуир 2017

Задание С. Мах-ћеар



Задание Б. Декодирование Хаффмана



Кафедра экономической информатики Бгуир 2017

66

Задание С. Мах-ћеар

```
private class MaxHeap
    //тут запишите ваше решение.
    //Будет мало? Ну тогда можете его собрать как Generic и/или использовать в варианте В
   private List<Long> heap = new ArrayList<>();
                                                                 //эта процедура читает данные из файла, ее можно не менять.
                                                                Long findMaxValue(InputStream stream) {
                                                                   Long maxValue=0L;
    int siftDown(int i) { //просеивание вверх
                                                                   MaxHeap heap = new MaxHeap();
                                                                   //прочитаем строку для кодирования из тестового файла
                                                                   Scanner scanner = new Scanner(stream);
        return i;
                                                                   Integer count = scanner.nextInt();
                                                                   for (int i = 0; i < count; ) {
                                                                      String s = scanner.nextLine();
                                                                      if (s.equalsIgnoreCase("extractMax")) {
   int siftUp(int i) { //просеивание вниз
                                                                         Long res=heap.extractMax();
                                                                         if (res!=null && res>maxValue) maxValue=res;
                                                                         System.out.println();
        return i;
                                                                      if (s.contains(" ")) {
                                                                         String[] p = s.split(" ");
    void insert(Long value) { //BCTABKA
                                                                         if (p[0].equalsIgnoreCase("insert"))
                                                                            heap.insert(Long.parseLong(p[1]));
                                                                      //System.out.println(heap); //debug
    Long extractMax() { //извлечение и удаление максимума
        Long result = null;
                                                                   return maxValue;
                                                  Insert 200
        return result;
                                                  Insert 10
    !!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!
                                                 ! ExtractMax
                                                   Insert 5
                                                  Insert 500
                                                  ExtractMax
```